

NEURON AS AN AGENT

Anonymous

ABSTRACT

The reason why swarm of agents solve real-world problem well is, interestingly, same as the principle of representation learning: good representation improves performance of machine learning. Most of the problem in real-world is not Markov decision process (MDP) but partially observed MDP (POMDP). On the POMDP environment, good observation yields good action. In this paper, we optimise a deep neural network as a multi-agent system as a natural extension from representation learning to multi-agent reinforcement learning for POMDP. To achieve that, we propose a novel learning framework, neuron as an agent (NaaA). In NaaA, an individual unit is considered as an agent, and they maximizing profit instead of minimizing error. To prevent dilemma, we borrow idea from mechanism design, a field of game theory. To this end, we show all the unit have valid price reflecting their contribution to performance at convergence. We confirm the result by numerical experiment using Atari and VizDoom.

1 INTRODUCTION

Deep reinforcement learning (DRL) succeed in many area. Deep Q-Network (DQN) (Mnih et al., 2015; Silver et al., 2016) decides the optimal action from screen sequence of atar, and selects the move closest to win from a face of a board of Go. Deep Deterministic Policy Gradient (DDPG) (Lillicrap et al., 2015) realizes the multiple-join control considering condition such as friction and gravity factor in a physical space. The applicable are of DRL is becoming wider year by year, the reasonable performance is reported 3D game such as Doom (Dosovitskiy & Koltun, 2016).

The reason why a neural network is workable for DRL is that a neural network abstracts the implicit state in an environment, and obtains informative state representation. From the micro perspective, the abstraction capability of each unit contributes to return of the entire system. So, we address the one following question.

Will reinforcement learning work even if we consider each of units as an autonomous agent?

The contribution of this paper is that, we propose *Neuron as an Agent* (NaaA) as a novel framework for RL, and show its optimizing method. NaaA considers all the units in a neural network as agents, and optimizes the reward distribution as a multi-agent RL problem. In the reward design of NaaA, a unit distributes its received reward to other input units passing its activation to the unit as cost. Hence, the actual reward is profit which defined as difference between inflow (received reward) and outflow (paid cost). In the setting, the economic metaphor can be introduced: profit is balance of revenue and cost. It means that a unit should address trade-off between both optimization of cumulative revenue maximization and cumulative cost minimization.

This paper is organized as below. Firstly, with showing the optimization of NaaA, we report the negative result that the performance decreases if we naively consider the units as agents. As solution of the problem, we introduce a mechanism of auction which applying game theory. As theoretical result, we show that the agent obeys to maximize its *counterfactual return* as the Nash equilibrium. Counterfactual return is the one which we extend counterfactual reward, the criterion which proposed for multi-agent reward distribution problem (Agogino & Tumer, 2006), along time axis.

After that, we show that learning counterfactual return leads the model to learning optimal topology between the units, and propose *adaptive dropconnect*, a natural extension of dropconnect (Wan et al., 2013). Adaptive dropconnect combines dropconnect, which pure-randomly masks the topology, with adaptive algorithm, which prunes the connection with less counterfactual return with higher probability. It uses ϵ -greedy as a policy, and is equivalent to dropconnect in the case of $\epsilon = 0$, and is

equivalent to counterfactual return maximization which constructs the topology deterministically in the case of $\varepsilon = 1$.

At the last, we confirm that optimization with the framework of NaaA leads better performance of RL, with numerical experiments. Specifically, we use a single-agent environment from Open AI gym, and multi-agent environment from ViZDoom.

Although considering all the units as agents might be vacuity at first glance, it has wider applicable area. At the perspective of optimization for single neural network, it can apply to pruning by optimizing the topology. Not only that, introducing the concept of reward distribution divides the single neural network to a lot of autonomous parts. It enable us to not only address sensor placing problem in IoT for partially observed Markov decision process (POMDP), but arbitrary incentivized participants can join the framework.

2 RELATED WORK

受け取る報酬に相関があるマルチエージェントの設定を意図的に作り出すことで、目的を達成するニューラルネットワークの学習のためのアイデアが最近注目されている。generative adversarial nets (GAN) (Goodfellow et al., 2014) は、generator と discriminator という報酬が相反する 2 つのエージェント間の競合ゲームを通し、両者の個別最適であるナッシュ均衡として、真の生成分布を得ることが目的である。ゲーム理論では、全体の報酬を最大化する結果のことをパレート最適と呼ぶが、一般にナッシュ均衡がパレート最適に収束することは保証されておらず、両者の不一致はジレンマと呼ばれる。ジレンマが存在するか否かは報酬設計に依存しているため、最適報酬設計を通してジレンマを解消する方法が研究されている。これは逆ゲーム理論 (inverse game theory) としても知られるメカニズムデザイン (Myerson, 1983) である。メカニズムデザインは、オークション (Vickrey, 1961) やマッチング (Gale & Shapley, 1962) に応用されている。GAN、そして本研究で提案する NaaA は、メカニズムデザインの一つである。NaaA では、メカニズムデザインの一つである digital goods auction (Guruswami et al., 2005) を応用することで、ナッシュ均衡として、ユニットが系全体のリターンを最大化することを示す。

NaaA は、複数のニューロンをエージェントとして処理することから、Dec-POMDP (decentralized POMDP) のクラスに属する。Dec-POMDP は、POMDP 環境に複数エージェントを想定している強化学習のクラスであり、様々な研究課題がある。一つはコミュニケーションである。CommNet (Sukhbaatar et al., 2016) はニューラルネットワークに属するユニットが他のユニットのトポロジーに対して agnostic である性質を応用し、マルチエージェントのコミュニケーションの訓練にバックプロパゲーションを応用している。もう一つは報酬の分配である。CommNet は全エージェントに、系が受け取った報酬を分配することを前提としているが、エネルギーや通貨のように全量が限られている報酬の場合は分割が困難である。QUICR-learning (Agogino & Tumer, 2006) では、エージェント i が reward $R(a_t)$ の代わりに、そのエージェントがある行動 a_{it} をとった場合 a_t と取らなかった場合 $a_t - a_{it}$ の差、counterfactual reward $R(a_t) - R(a_t - a_{it})$ の cumulative discount summation を最大化している。COMA (Foerster et al., 2017) は、actor-critic において critic が共通しており、actor がマルチエージェントであるという actor-critic の仕組みを考え、それぞれの actor が counterfactual reward を最大化するような仕組みを考えている。本研究は、これら二つの問題を統一的に扱い、エージェントが自身の counterfactual return を最大化するように行動する仕組みを提案する。

神経科学モデルから見ても、ニューロンは一つの細胞として機能するため、エネルギーやニューロトロフィンを消費する、アポトーシスを起こすなど自律的な振る舞いをする。このため、本質的には複数のレイヤー、複数のユニットを異なるオーナーが作り、フォワード/バックプロパゲーションのコミュニケーションのみで、全体最適化を行うことができる。その場合は貢献度に応じた報酬を分け合う必要がある。我々の提案するフレームワーク、NaaA はこうした仕組みをモデリングしている。

TODO: Dropconnect

3 BACKGROUND

まず、単一のエージェントが POMDP 環境で行動する場合について考える。POMDP 環境とは 7 つ組 $(\mathcal{S}, \mathcal{A}, \mathcal{T}, \mathcal{R}, \Omega, \mathcal{O}, \gamma)$ である。ただし、 \mathcal{S} は状態集合、 \mathcal{A} は行動集合、 \mathcal{T} は遷移確率、

Ω は取りうる観測の集合、 \mathcal{O} は観測の集合、 γ は減衰率である。エージェントは観測 $o \in \Omega$ を通して部分的に状態 S を推定する。一般に o の方が s よりも次元が大きく、複雑である。たとえば、Atari 2600 は真の状態である RAM は 128 バイトしかないが、そこから生成される画像 o は 10,000 以上の次元を持っている。そのため、DQN や DRQN では、 o の情報を抽象化し、独自の状態表現を作っていると解釈できる (DQN の原著論文では MDP であることを前提としているが、DRQN の論文で環境が POMDP であることが主張されている)。もちろん、DQN はモデルフリーの手法であるため、直接は状態遷移を扱わないが、出力層の一個手前の層に状態が格納されているという解釈もできる (Zahavy et al., 2016)。以下では、エージェントはニューラルネットワークを通して行動を決定することを前提とする。

次に、互いに通信するマルチエージェントシステムを考える。一般にエージェントが多いほど、観測を増やすことが可能である。たとえば、自動運転のケースでは自動車同士が通信することでより正確な世界に対する知識を得ることができる。この時、エージェントが持っているニューラルネットワーク同士をつなげる方法がとられている (Sukhbaatar et al., 2016)。これは、マルチエージェントシステム全体を一つのニューラルネットワークをとらえることができると考えられる。そこで、本研究ではこれを拡張し、すべてのユニットをエージェントとみなす。

4 NEURON AS AN AGENT

ニューラルネットワークを、ユニット間の有向グラフ $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ で表す。 $\mathcal{V} = \{v_1, \dots, v_N\}$ はユニットの集合であり、 $\mathcal{E} \subset \mathcal{V}^2$ はユニットの接続関係を表すエッジの集合である。 $(v_i, v_j) \in \mathcal{E}$ であるとき、 $v_i \rightarrow v_j$ という接続関係が成立し、 v_j は v_i から値を入力する。ユニットの v_i の時刻 t における出力を $x_{it} \in \mathbb{R}$ で表す。ユニット i の出力先の集合を $N_i^{\text{out}} = \{j | (v_i, v_j) \in \mathcal{E}\}$ 、入力元の集合を $N_i^{\text{in}} = \{j | (v_j, v_i) \in \mathcal{E}\}$ で表現する。 $N_i = N_i^{\text{in}} \cup N_i^{\text{out}}$ とする。

NaaA は v_i をエージェントとしてとらえる。すなわち、 \mathcal{G} はマルチエージェントシステムである。 v_i にとっての環境は、マルチエージェントシステムの自体が触れている環境と、 v_i が直絶接続しているユニット群 $\{v_i \in V | i \in N_j\}$ である。前者を外的環境 (external environment)、後者を内的環境 (internal environment) と呼んで区別する。 v_i は環境から報酬を受け取る。 v_i の性質として以下の前提を加える。

- N1: (利己性) v_i は、各時点 t において、汎化誤差の最小化ではなく、自身のリターン (累積減衰報酬) $G_{it} = \sum_{k=0}^T \gamma^k R_{i,t+k}$ の最大化を目的として行動する。ただし $\gamma \in [0, 1]$ は減衰率 (discount rate)、 T は終端時間である。
- N2: (保存則) v_i が内的環境と外的環境の両方から受け取る報酬 R_{it} の総和は、マルチユニットシステム全体が外的環境から得る報酬 R_t^{ex} に等しい。
- N3: (取引) v_i は信号 x_i を $v_j \in \mathcal{V}$ に伝達する際に、信号と引き換えに報酬 ρ_{jit} を受け取る。同時に ρ_{jit} は v_j の報酬から差し引かれる。
- N4: (NOOP) v_i は、期待リターンが $\delta > 0$ の NOOP (no operation) という行動をオプションとして持つ。NOOP では、ユニットは何も入力せず、何も出力しない。

N1 はユニットがエージェントとして振る舞うことを述べている。N2, N3 は NTF の分配に、N4 はニューロンのアポトーシスに相当する。NOOP が選択されるのは、それ以外のすべての行動の期待報酬が非正であった場合である。以下ではこれらの前提から出発して、NaaA の仕組みを構築していく。

4.1 CUMULATIVE DISCOUNTED PROFIT MAXIMIZATION FRAMEWORK

ユニット i が時刻 t で外的環境から得る報酬を R_{it}^{ex} と書く。ただし、 $\sum_{i=1}^n R_{it}^{\text{ex}} = R_t^{\text{ex}}$ である。N3 より、時刻 t に i が獲得する報酬 R_{it} は次のように表現される。

$$R_{it} = R_{it}^{\text{ex}} + \sum_{j \in N_i^{\text{out}}} \rho_{jit} - \sum_{j \in N_i^{\text{in}}} \rho_{ijt}. \quad (1)$$

この式は、符号が正の項と負の項の二つに分解される。前者を収益 (revenue)、後者をコスト (cost) と呼び、それぞれ $r_{it} = R_{it}^{\text{ex}} + \sum_{j \in N_i^{\text{out}}} \rho_{jit}$, $c_{it} = \sum_{j \in N_i^{\text{in}}} \rho_{ijt}$ で表す。 R_{it} を利益 (profit) と呼ぶ。

このとき、ユニット v_i は、次式で表現される累積減衰利益 G_{it} を最大化する。

$$G_{it} = \sum_{k=0}^T \gamma^k R_{i,t+k} = \sum_{k=0}^T \gamma^k (r_{i,t+k} - c_{i,t+k}). \quad (2)$$

$R_{it} > 0$ 、すなわち、 $r_{it} > c_{it}$ であれば、ユニットは得たデータに対して付加価値を与えていることになる。もし、すべての t に対して $R_{it} \leq 0$ であれば、 $G_{it} \leq 0 < \delta$ であるから、ユニットは NOOP になる。

5 OPTIMIZATION

NaaA では利益を最大化するため、二つの相反する指標である収益 r_{it} とコスト c_{it} のバランスを取ることが重要になる。本研究では、この最適化にゲーム理論の一つであるメカニズムデザインを応用する。メカニズムデザインは、マルチエージェントシステムを対象にしたゲーム理論の分野であり、各エージェントが利己的であることを想定した上で、システム全体が最適になるような帰結を目指すメカニズムの設計を目的とするものである。

TODO: 否定的な結論

メカニズムデザインを導入する理由は、NaaA いくつかの既存研究と異なり、すべてのエージェントが協力的ではなく、利己的であると仮定していることに起因している。前述の問題は、そのまま最適化すると報酬額は 0 に収束するため、すべてのニューロンが NOOP になるという trivial な解が得られる。マルチエージェントシステムは無情報でアクションを選択する必要が生じ、これはランダムなアクションを取っている状況に等しい。したがって、明らかに外的環境からの報酬 R_t は小さくなる。

このように最適化を行った結果、システム全体が最適化されない現象はジレンマとして知られており、囚人のジレンマ問題をはじめとした様々な研究が行われている。しかし、一般にエージェントが利己的であると仮定した場合の最適化は難しいとされている。メカニズムデザインはこうした問題を解決することができる。

5.1 ENVY-FREE AUCTION

パレート効率な仕組みを作るために、我々はオークション理論における digital goods auction からアイデアを借りる。オークション理論は、ゲーム理論におけるメカニズムデザインという分野に属しており、複数のエージェントの利害を一致させ、全体としてパレート最適を目指すことを目指している。digital goods auction は、本や音楽などの、複製可能な財を割り当てる仕組みを作っている。

Digital goods auction にはいくつかバリエーションがあるが、本研究では単純な前提のみを設けるだけでよいという理由から envy-free auction (Guruswami et al., 2005) を用いる。これは、同じ時点取引において、一つのユニットの価格を同じにするというものである。NaaA において、これは次の前提によって表現できる。

N5: (一物一価) $\rho_{j_1,i,t}, \rho_{j_2,i,t} > 0$ であれば $\rho_{j_1,i,t} = \rho_{j_2,i,t}$

これは、ユニット v_i は同じ時間 (timing) t に個有の価格を持つことを意味する。この価格を q_{it} で表す。

Envy-free auction の流れを Figure 1 の左に示す。図は、信号を送信する一つのユニットと、その信号を「購入」する複数のユニットに分かれ、交渉の過程を示している。一単位の交渉は、強化学習の時間軸では 1 ステップ内に完了し、これが複数回繰り返されることになる。信号を送信する側を売り手、受信する側を買い手と呼ぶ。買い手はユニットに対して入札 b_{jit} を行う (1)。次に、入札額をもとに、売り手は価格 \hat{q}_{it} を決定し、割当を行う (2)。このとき、 $b_{jit} \geq \hat{q}_{it}$ であれば割当を行って $g_{jit} = 1$ とし、そうでなければ $g_{jit} = 0$ とする。割当を行った後は、 $\rho_{jit} = g_{jit}\hat{q}_{it}$ として、送金を行い (3)、売り手は割当を行ったノードに対してのみ信号 x_i を送付する (4)。信号を受け取れなかったノードは、 x_i の期待値 $\mathbb{E}_\pi[x_i]$ によって x_i を近似する。

G_{it} は次のように書くことができる。

$$\begin{aligned} G_{it} &= r_t - c_t + \gamma G_{i,t+1} \\ &\approx r_t - c_t + \gamma V_i^{\pi_i}(s_{i,t+1}), \end{aligned} \quad (3)$$




Figure 1: Left: NaaA による取引の流れ。Right: ユニットの価格決定方法。ユニットの収益は単調減少な需要と価格の積となり、これを最大化する価格が最適価格となる。

ただし、 $V_i^{\pi_i}(s_{it})$ は価値関数 (value function) であり、ユニットの状態 s_{it} に対して方策 π_i を取った場合のリターンの期待値に等しい。このため、収益、コスト、価値関数それぞれを最大化する方法について考えればよい。

Revenue: エージェントの収益は次式で与えられる。

$$\begin{aligned} r_{it} &= \sum_{j \in N_i^{\text{out}}} g(b_{jit}, q_{it}) q_{it} + R_i^{\text{ex}} = q_{it} \sum_{j \in N_i^{\text{out}}} g(b_{jit}, q_{it}) + R_i^{\text{ex}} \\ &= q_{it} d_{it}(q_{it}) + R_i^{\text{ex}}, \end{aligned} \quad (4)$$

ただし、 $g(\cdot, \cdot)$ は割当 (allocation) であり、ステップ関数 $H(\cdot)$ を用いて $g(b, q) = H(b - q)$ によって定義される。 q_{it} は価格、 $d_{it}(q_{it})$ はユニット i の信号に対する価値を q_{it} 以上と評価しているエージェントの数であり、需要 (demand) と呼ぶ。同様の式で、右辺を最大化する a を最適価格と呼び、 \hat{q}_{it} で表す。第二項は q_t に対して独立であるから、最適価格 \hat{q}_{it} は次のようにして与えられる。

$$\hat{q}_{it} = \operatorname{argmax}_{q \in [0, \infty)} q d_{it}(q). \quad (5)$$

この仕組みを、Figure 1 の右に図示する。 $d_t(q_{it})$ は単調減少な関数であり、収益 r_{it} は q_{it} と $d_t(q_{it})$ との積によって表現される。

Cost: コストは、ユニットが他のユニットに対して払う価格である。これは次のように表示される。

$$c_{it} = \sum_{j \in N^{\text{in}}} g(b_{ijt}, q_j) q_j + \alpha_i \quad (6)$$

c_{it} 自体は $b_{ijt} = 0$ のとき最小となる。しかし、これは次の value function とトレードオフをなす。

Value Function: 価値関数は $V(s_{i,t+1})$ の値は $s_{i,t+1}$ に依存する。既に述べたようにエージェントの v_i の環境は接続されているユニット集合であり、ユニットの出力はこれらのエージェントからの評価、すなわちエッジの重みに影響を及ぼす。通常のニューラルネットワークでは、出力の精度に貢献しないニューロンの重みは小さくなることから、報酬は小さくなる。したがって、入札価格 b_{ijt} を最小化し 0 と置くとデータの購入に失敗し、将来的にエージェントが接続しているエージェントから得られる報酬が小さくなる。

今、割当を $\mathbf{g}_{it} = (g_{i1t}, \dots, g_{iN_t})^T$ で表し、エージェントが v_j の購入に成功した場合と、そうでない場合に価値関数に及ぼす影響について考える。この時、価値関数は、状態価値関数

$Q(s_{i,t+1}, \mathbf{g}_{i,t+1})$ を用いて次式で表現できる。

$$\begin{aligned}
V_i^{\pi_i}(s_{it}) &= Q_i^{\pi_i}(s_{it}, \mathbf{g}_{it}) \\
&= \sum_{j \in N_i^{\text{in}}} g_{ijt} (Q_i^{\pi_i}(s_{it}, \mathbf{e}_j) - Q_i^{\pi_i}(s_{it}, \mathbf{0})) + Q_i^{\pi_i}(s_{it}, \mathbf{0}) \\
&= \sum_{j \in N_i^{\text{in}}} g_{ijt} o_{ijt} + Q_i^{\pi_i}(s_{it}, \mathbf{0}) \\
&= \mathbf{g}_{it}^T \mathbf{o}_{it} + Q_i^{\pi_i}(s_{it}, \mathbf{0})
\end{aligned} \tag{7}$$

$o_{ijt} = Q_i^{\pi_i}(s_{it}, \mathbf{e}_j) - Q_i^{\pi_i}(s_{it}, \mathbf{0})$ を *counterfactual return* と呼ぶ。これは、counterfactual reward の cumulative discounted summation である QUICR (Agogino & Tumer, 2006) と導出は異なるが等価である。すなわち、エージェントが支払うコストは、データの購入に成功した場合は \hat{q}_{it} であり、それ以外は o_{it} となる。

以上から、最適化問題は次のように書くことができる。

$$\max_{\mathbf{b}, q} G_{it} = \max_q qd_{it}(q) - \min_{\mathbf{b}} \mathbf{g}_{it}(\mathbf{b})^T (\hat{\mathbf{q}}_t - \gamma \mathbf{o}_{i,t+1}) + \text{const.} \tag{8}$$

では、リターンを最大化するためのエージェントの入札額 b_{it} は何か。これについては次の定理が成立する。

Theorem 5.1. (Truthfulness) リターンを最大化する最適な入札額は $\hat{\mathbf{b}}_{it} = \mathbf{o}_{it}$ である。

証明については Appendix を参照。

すなわち、エージェントは自身の counterfactual return のみを問題にすればよい (!) したがって、NaaA のメカニズムでは、エージェントはあたかも他のエージェントを価値評価 (valuation) し、その価値を正直に申告していることを意味する。

系として次の解が得られる。

Corollary 5.1. *The Nash equivalence of the envy-free game $(\mathbf{b}_{it}, q_{it})$ is $(\mathbf{o}_{it}, \arg\max_q qd_{it}(q))$.*

5.2 VALUATION NET

残る問題は、 \mathbf{o}_t をいかに推定するかである。この推定には様々な方法が存在しており、多くのメソッドを使うことができるが、本論文では Q の推定に Q -learning を採用する。ただし、SARSA や actor-critic などの on-policy な方法も使うことができることを補足する。

図 2 に示す Valuation Net は、通常のニューラルネットワークのユニットに、 Q -learning による valuation を組み合わせたネットワークである。まず、上部はエージェント間の通信について示したものである。ニューラルネットワークではユニットを円で表現するのが通例であるが、ここではユニットをエージェントとしてみなすことを強調して、六角形で一つのユニットを表現している。エージェント間では、通常のニューラルネットワークと同様の信号の通信以外に、取引に関する通信 (allocate, buy, sell & bid) が発生する。

Valuation Net では、状態 \mathbf{s}_t として、予測後入力 $\tilde{\mathbf{x}}_t$ および入力に依存しない構成情報 \mathbf{u} を横につなげたベクトル $(\tilde{\mathbf{x}}_t^T, \mathbf{u}^T)^T$ を用いる。構成情報の一例としてはユニットのパラメータがあげられ、たとえば重みやバイアスの情報を用いることができる。

状態からの Q 関数の予測にニューラルネットワークを用いる。エージェントが受け取った収益に基づき時間差分 (TD)-誤差 が計算され、ネットワークが訓練される。ネットワークの構成にはこれまでの deep Q -learning で用いられている二重化ネットワーク (dueling network) (Wang et al., 2015) のテクニックを用いる。オリジナルの文献 (Wang et al., 2015) で述べられている二重化ネットワークは、学習を加速するために、状態関数と、 Q 関数との差分を別々に予測する手法である。Dosovitskiy & Koltun (2016) はこれに対して、差分の要素の総和が 0 になるように正規化するように改良している。本研究では Dosovitskiy & Koltun (2016) の手法に従い、期待値 $\mathcal{E}(\mathbf{s}_t)$ と正規化差分 $\tilde{A}(\mathbf{s}_t)$ を別々に求める。




Figure 2: Valuation Net は情報の価値を評価し、bidding price を決定する。下位のニューロンに対して入札し、信号を購入する。購入したデータを用いて、データを次のニューロンに対して売る。

Q 関数は次のように表現される。

$$Q(s_t, a_t) = \mathcal{E}(s_t) + \tilde{A}(s_t, a_t)$$

$$\sum_{i=1}^k \tilde{A}_i(s_t, a_t) = 0 \quad (9)$$

第2式を満たすために、まず、 s_t に基づいた予測を行い、次のような正規化を行う。

$$\tilde{A}_i(s_t, a_t) = A_i(s_t, a_t) - \frac{1}{k} \sum_{j=1}^k A_j(s_t, a_t) \quad (10)$$

次に、valuation を行い、bidding price \mathbf{b}_t を求める。 $\hat{b}_{ijt} = o_{ijt}$ 式9より、最適な入札価格 \hat{b}_{it} は次のように計算できる。

$$\hat{b}_{ijt} = \tilde{A}(s_t, 1) - \tilde{A}(s_t, 0) \quad (11)$$

Valuation Net ではこの式に基づき、advantage の出力を引き算することで入札価格を計算している。

6 EXPERIMENT

6.1 SINGLE-AGENT ENVIRONMENT

6.2 MULTI-AGENT ENVIRONMENT

6.2.1 ViZDOOM

To 阿久澤君: この執筆をお願いできないでしょうか

7 DISCUSSION

7.1 DISADVANTAGE

Disdvantage としてまず挙げられるのは計算量である。Envy-free auction では需要の計算にソーットの演算が入るために、直列化しなければならない箇所があるため、これらについては近似を行うなどして改善していく必要がある。

個別の最適化技術について述べると、Envy-free auction は、買い手のエージェント同士の価格がわからない sealed な状態であれば、正直性 (truthfulness) が成り立つが、一方で買い手同士がコミュニケーションを行い価格を共有し合う状態においては、買い手が自由に価格を偽装できることが知られている。これについては、Goldberg et al. (2006) によって解決方法が示唆されている。

Valuation Net は、用いるニューラルネットワークによっては実装が困難であることがある。これは著者らの GitHub に Linear と CNN は公開しているが、RNN などについては今後の研究課題となる。

7.2 APPLICATION

NaaA は、ネットワークが分散されている環境での学習や、サブモジュールでの制御に有用である。具体的に、以下の技術に応用が可能である。

- ハイパーパラメータチューニング。Neuroevolution など、遺伝的アルゴリズムを用いてハイパーパラメータチューニングを用いるアルゴリズムがすでにいくつか提案されている。このとき、fitness 関数として利益を用いることで、より強化学習の目的に特化したニューラルネットワークを得ることができると考えられる。
- pruning, dilution などのネットワークの規模の縮小。
- アテンション制御。一部のアテンションの研究では、強化学習を用いてアテンションの制御を行っている。
- アンサンブル。複数のモデルの混合に今回の技術を用いることができる。

これらの応用に関しては、今後の研究の方向性である。

8 CONCLUSION AND FUTURE WORKS

本論文では、POMDP の問題設定において良質な特徴表現を得るために、ニューラルネットワーク上の各ユニットをエージェントとして扱うフレームワーク、NaaA について述べた。NaaA のフレームワークでは、ジレンマ問題を解決し、それぞれのエージェントの持つ付加価値がナッシュ均衡として得られ、全体としてパレート最適になることを示した。入札価格の決定アルゴリズムの一つとして、 Q -learning に基づくネットワーク Valuation Net を示した。評価実験では、Atari と VizDoom を用いた実験を行い、実験結果が既存手法よりもよくなることを示した。

今後の方向性として、高速化、Valuation Net を A3C などの on-policy な手法で置き換えるといった方向性の他、神経科学的な説明を可能にしていくといった方法、遺伝的アルゴリズムとの組み合わせが挙げられる。

APPENDIX

A.1 定理 5.1 の証明

買い手の獲得する生涯報酬 G は次で与えられる。

$$G(b, q) = g(b, q) \cdot (v - q) + G_0, \quad (12)$$

ただし、 g は割当 (allocation) であり、 G_0 はユニットを購入しなかった場合の生涯報酬である。割当は、 $g(b, q) = H(b - q)$ が成立する。 H はステップ関数である。

買い手にとって売り手が提示する asking price q は未知であるため、 q を台 $[0, \infty)$ の上の確率変数であるとして扱い、期待値 $\mathbb{E}_q [G(b, q)]$ を最大化することを考える。このとき、

$$\begin{aligned}\frac{\partial}{\partial b} \mathbb{E}_q [G(b, q)] &= \frac{\partial}{\partial b} \int_0^\infty (H(b - q) \cdot (v - q) + G_0) p(q) dq \\ &= \frac{\partial}{\partial b} \left[\int_0^b (v - q) p(q) dq + G_0 \int_0^\infty p(q) dq \right] \\ &= \frac{\partial}{\partial b} \int_0^b (v - q) p(q) dq \\ &= (v - b) p(q = b)\end{aligned}$$

したがって、 $\mathbb{E}_q [G(b, q)]$ が最大となるための条件は $b = v$ ある。

REFERENCES

- A. K. Agogino and K. Tumer. QUICR-learning for multi-agent coordination. AAAI’06, 2006.
- A. Dosovitskiy and V. Koltun. Learning to act by predicting the future. *ICLR’17*, 2016.
- J. Foerster, G. Farquhar, T. Afouras, N. Nardelli, and S. Whiteson. Counterfactual multi-agent policy gradients. *arXiv:1705.08926*, 2017.
- D. Fox, W. Burgard, H. Kruppa, and S. Thrun. A probabilistic approach to collaborative multi-robot localization. *Autonomous robots*, 8(3):325–344, 2000.
- David Gale and Lloyd S Shapley. College admissions and the stability of marriage. *The American Mathematical Monthly*, 69(1):9–15, 1962.
- Andrew V Goldberg, Jason D Hartline, Anna R Karlin, Michael Saks, and Andrew Wright. Competitive auctions. *Games and Economic Behavior*, 55(2):242–269, 2006.
- I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In *Advances in neural information processing systems*, pp. 2672–2680, 2014.
- Venkatesan Guruswami, Jason D Hartline, Anna R Karlin, David Kempe, Claire Kenyon, and Frank McSherry. On profit-maximizing envy-free pricing. In *ACM-SIAM symposium on Discrete algorithms*, 2005.
- Shivaram Kalyanakrishnan, Yaxin Liu, and Peter Stone. Half field offense in robocup soccer: A multiagent reinforcement learning case study. In *Robot Soccer World Cup*, pp. 72–85. Springer, 2006.
- T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra. Continuous control with deep reinforcement learning. *ICLR’16*, 2015.
- V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver, and K. Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *ICML’16*, pp. 1928–1937, 2016.
- Roger B Myerson. Mechanism design by an informed principal. *Econometrica: Journal of the Econometric Society*, pp. 1767–1797, 1983.
- A. Nair, P. Srinivasan, S. Blackwell, C. Alcicek, R. Fearon, A. De Maria, V. Panneershelvam, M. Suleyman, C. Beattie, S. Petersen, et al. Massively parallel methods for deep reinforcement learning. *ICML’15*, 2015.

- David E Rumelhart, Geoffrey E Hinton, and Ronald J Williams. Learning internal representations by error propagation. Technical report, California Univ San Diego La Jolla Inst for Cognitive Science, 1985.
- D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. Van Den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.
- S. Sukhbaatar, R. Fergus, et al. Learning multiagent communication with backpropagation. In *NIPS’16*, 2016.
- A. Tampuu, T. Matiisen, D. Kodelja, I. Kuzovkin, K. Korjus, J. Aru, J. Aru, and R. Vicente. Multi-agent cooperation and competition with deep reinforcement learning. *PloS one*, 12(4):e0172395, 2017.
- William Vickrey. Counterspeculation, auctions, and competitive sealed tenders. *The Journal of finance*, 16(1):8–37, 1961.
- Li Wan, Matthew Zeiler, Sixin Zhang, Yann L Cun, and Rob Fergus. Regularization of neural networks using dropconnect. In *Proceedings of the 30th international conference on machine learning (ICML-13)*, pp. 1058–1066, 2013.
- Z. Wang, T. Schaul, M. Hessel, H. Van Hasselt, M. Lanctot, and N. De Freitas. Dueling network architectures for deep reinforcement learning. *arXiv:1511.06581*, 2015.
- T. Zahavy, N. Ben-Zrihem, and S. Mannor. Graying the black box: Understanding DQNs. In *ICML’16*, 2016.